Introduction to Python and Programming Language

Koscom Algorithm Lecture

신승우

Wednesday 5th September, 2018

Outline

What is Parsing?

Parsing

특정 형식에 맞는 문자열을 원하는 데이터구조 형태로 만드는 것

- **특정 형식**에 맞는 문자열 : Formal Grammar
- **원하는 데이터구조** : Abstract Syntax Tree(AST)

수식의 Grammar

수식의 grammar를 살펴보면 다음과 같다.

```
1) expr -> part (binary part)*
2) part -> num \| "(" expr ")" |  unary part ;
3) binary -> "^" \| "*" \| "/" \| "+" \| "-" ;
4) unary -> "-" ;
5) num -> r"[a-zA-Z]+" | r"[1-9][0-9]*\.?[0-9]*" ;
```

1)에서 (binary part)*는 binary part의 유한한 반복을 뜻한다. 0번 반복하더라도 상관없다.

Syntax Check using Grammar

위 문법에 기반하여 $x * (y + z)$ 가 수식의 문법에 맞는 문장인지 알아보자.

Table: $x * (y + z)$ 체크

current string	rule	result
x*(y+z)	1	is x part?, is * binary?, is (y+z) part?
x	2, 3	x is num! / num is part!
*	3	* is binary!
(y+z)	3	is y+z expr?
y, z	same to x	y,z is num! / num is part!
+	3	+ is binary!

Syntax Check using Grammar

이번에는 $x*(y+$ 가 수식의 문법에 맞는 문장인지 알아보자.

Table: $x*(y+$ 체크

current string	rule	result
x*(y+	1	is x part?, is * binary?, is (y+ part?
x	2, 3	x is num! / num is part!
*	3	* is binary!
(y+	3	is y+ expr?
y	same to x	y is num! / num is part!
+	3	+ is binary!
eos	None	expected part, return eos : **SyntaxError**

이처럼, 위 문법에서의 규칙들을 순차적으로 적용하는 것으로 특정 문자열이 그 문법에 맞게 작성되었는지를 알 수 있다. 이럴 때 그 특정 문자열은 그 문법에 의해서 생성되었다고 한다.

Abstract Syntax Tree

구문의 문법 구조를 반영하여 트리 형태로 나타낸 것을 abstract syntax tree라고 한다. 예를 들어서, 위 $x * (y + z)$의 경우 다음과 같은 트리로 생각할 수 있다.

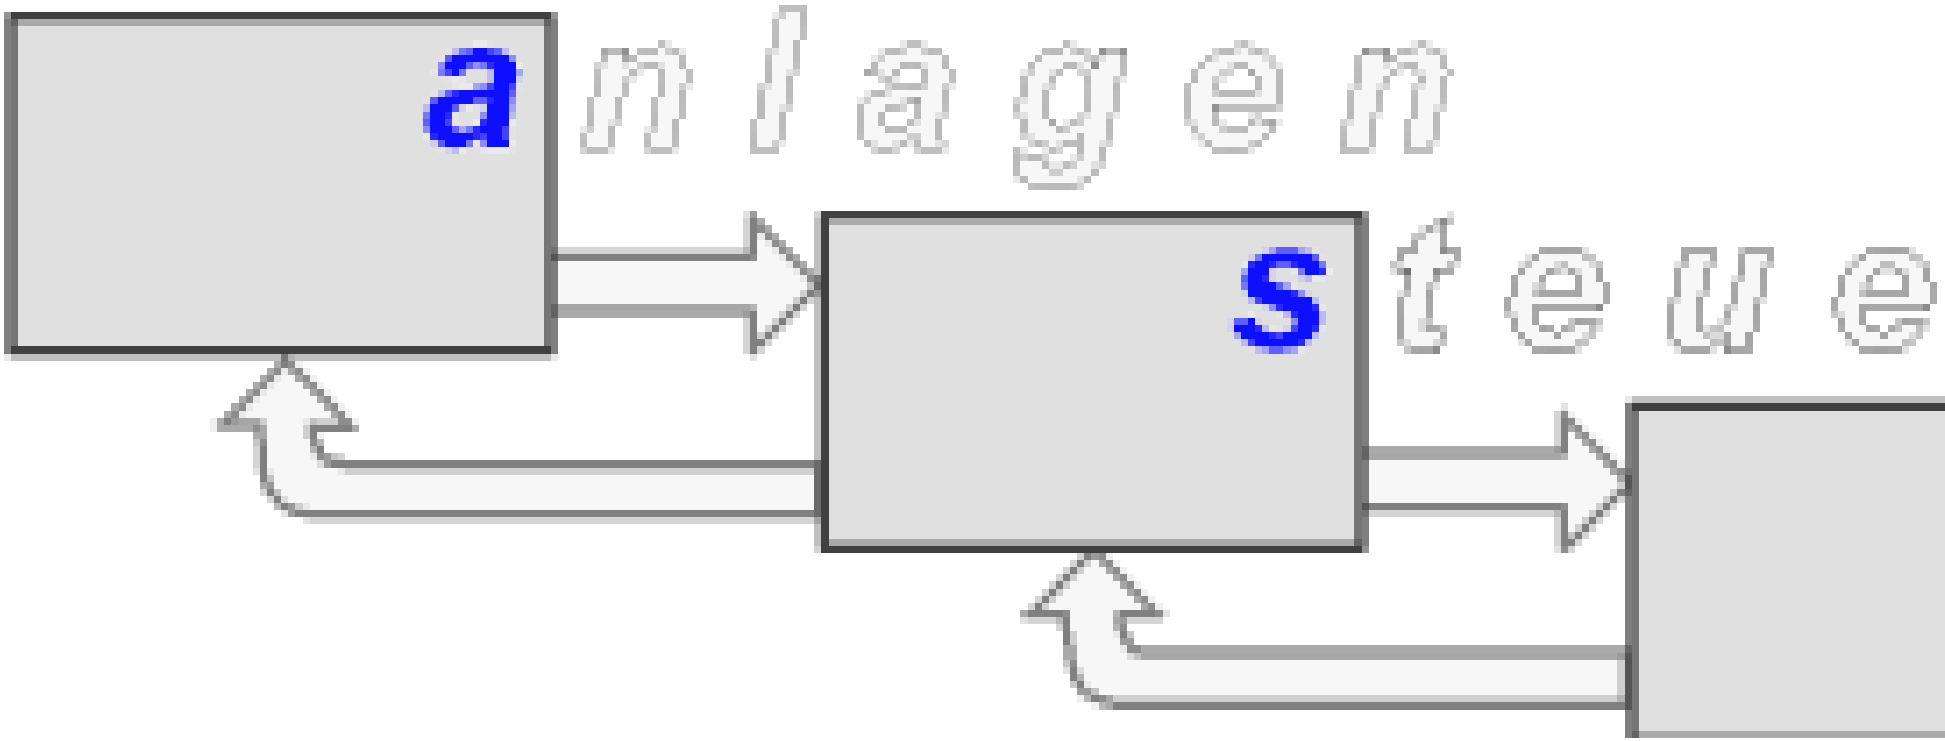

이때까지 문법과 그 문법을 이용하여 파싱한 결과물이 무엇인지 간략하게 살펴보았다. 이제 본격적으로 어떤 식으로 구현하는지 살펴 보고자 한다.

Parser Structure

먼저, 일반적인 파서의 구조를 살펴보자. 일반적으로 파서는 두 가지 함수로 이루어져 있다.

- tokenizer : string to tokens
- parser : tokens to AST

여기서, token이란 최소한의 의미를 가지는 문자열을 말한다. 문법에서 " 으로 둘러싸인 문자열이나 그 문자열이 나타내는 정규표현식과 일치하는 문자열을 뜻한다.

Implementing Tokenizer

Tokenizer의 경우, 다음의 과정을 통해서 만들 수 있다.

- 문법에서 token의 패턴을 추출한다.
- input string에 대해서, input string == "" 가 될 때까지
  - 각 패턴에 대해서 check re.match(pattern, input string)
  - 만약 맞으면 input string에서 pattern과 일치하는 부분을 yield
  - 일치하는 부분을 제외한 나머지를 input string으로 업데이트
  - 만약 모든 패턴에 대해서 맞지 않으면 SyntaxError 리턴

Shunting-Yard Algorithm

이제 얻어진 token들을 이용하여 abstract syntax tree를 만드는 알고리즘을 생각해 보자. 먼저, 스택 2개를 생각한다.

- operand stack
- operation stack

이 때, operation stack에서는 필요한 operand들이 파싱이 끝날 때까지 operation을 pop하지 않는다. 또한, operation들 중 더 우선순위가 높은 operation이 항상 스택의 위에 오도록 유지한다. 예를 들어서, operation stack에 /가 있을 때, +가 들어오기 전에 /를 pop하고 필요한 처치를 한다. 즉, 그 때 operand stack의 가장 위에 있는 token 2개를 pop[1] 하여 Tree('/', tok1, tok2) 형태로 만드는 것이다. 만약 그 때 operand stack에 2개의 token이 없다면 에러를 리턴한다. operator가 스택에서 pop될 때마다 tree가 하나씩 생성되며, 이를 다시 operand stack에 push한다.
파싱이 되는 예시 2개와, 되지 않는 예시 1개를 들어서 살펴보고 이를 구현해보겠다.

[1]만약 operation이 unary라면 1개. operation에 맞는 갯수를 리턴하면 된다.

예시

Table: $x * y + z$ 파싱 예제

tokens	operand	op	action
x, *, y, +, z			operand.push(x)
*, y, +, z	x		compare(*, None)
, y, +, z	x	*	operation.push(*)
y, +, z	x	*	operand.push(y)
+, z	y, x	*	compare(*, +)
+, z	Tree(*, [x, y])		operator.pop()
z	Tree(*, [x, y])	+	operation.push(+)
	z, Tree(*, [x, y])	+	operand.push(z)
	Tree(+, [z, Tree(*, [x, y])])		operation.pop()

예시

Table: $x * (y + z)$ 파싱 예제

tokens	operand	op	action
x, *, (, y, +, z,)			operand.push(x)
*, (, y, +, z,)	x		operation.push(*)
(, y, +, z,)	x	*	parse(find_match(toke
	Tree(+, [y,z]) x	*	operand.push(parse(..)
	Tree(+, [y,z]) x	*	operator.pop()
	Tree(*, [Tree(+, [y,z]), x])		operator.pop()

여기서 find_match 함수를 사용하는데, 이는 tokens에서 어떤 index의 괄호와 쌍을 이루는 괄호를 찾는 것이다. 이를 통해서 괄호 안의 식을 우선적으로 처리할 수 있다.

예시

Table: $y+$ 파싱 예제

tokens	operand	op	action
y, +			operand.push(y)
+	y		operator.push(+)
	y	+	operator.pop()
	y	+	operand.pop();operand.pop()
	y	+	raise SyntaxError

Implementing Parser

위에서 알고리즘의 개요를 살펴보았다. 이제 본 알고리즘을 구현해볼 것이다. 본격적인 구현 전에, 필요한 변수들과 함수들을 구현하자.

- precedence : operator들 간 우선순위를 저장한 변수
- find_match 함수 : 맞는 괄호 찾아주기
- compare 함수 : operator 간 우선순위 비교

이후, 스택 두 개를 만들어 위 알고리즘을 구현한다.

Implementing Parser : 실습/quiz

실습은 skeleton/PyFormula.py 에서 tokenizer 함수와 parser 함수를 짜서 아래의 test들을 다 통과하면 됩니다. Tree의 형태가 다르더라도 같은 식을 만들면 맞는 걸로 인정합니다. 문법은 다음과 같습니다.

```
1) expr -> part (binary part)*;
2) part -> num | "(" expr ")" ;
3) binary -> "+" | "-" | "*" | "/" | "^";
4) num -> r"[a-zA-Z]+" | r"[1-9][0-9]*\.?[0-9]*;
```

실습에서는

- operator 순서는 ^, (*, /), (+, -) 순입니다.
- **unary는 고려하지 않습니다.**
- tokenizer 함수는 token을 만드는 genertor나, list 형태로 리턴하면 됩니다.
- parser은 util.py에 있는 Tree의 인스턴스나 3-tuple 형태의 답을 리턴하면 됩니다. 예를 들어서 (1+2)*3 이라면, (* (+ 1 2) 3) 혹은 (* 3 (+ 1 2)) 형태로 출력하면 됩니다.